

西北師範大學

研究生學位論文開題報告

基於點雲數據表示的磁共振圖像
分割方法研究及應用

姓 名	劉柄汐
學 號	2022222292
學 院	計算機科學與工程學院
專 業	計算機技術
學 位 層 次	<input type="checkbox"/> 博士 <input checked="" type="checkbox"/> 碩士
學 位 類 別	<input type="checkbox"/> 學術學位 <input checked="" type="checkbox"/> 專業學位
指 導 教 師	蔣芸

研究生院 制

填 表 说 明

一、学位论文开题报告应按要求逐项认真撰写，各栏空格不够时请自行加页。

二、开题报告的撰写应当精炼，紧扣主题，概括而准确表达自己的观点。

三、学位论文开题报告须由研究生与指导教师讨论后，由研究生进行填写，经指导教师审阅通过并签署意见，硕士研究生方可参加开题，在开题小组会议上宣读，接受开题教师的质疑与评议。

四、学位论文开题报告经开题小组评审通过后，装订成册，一式两份，由学院和研究生各存一份。

五、学位论文开题报告中的标题及正文格式按照《西北师范大学研究生学位论文撰写格式及印制规格的规定》执行。

一、选题背景、意义和研究价值

1.1 研究背景

图像分割在定量医学图像分析中起着重要作用，因为它通常是解剖结构分析的第一步^[1]。医学影像分析为医疗专业人员提供了有用的指导，以了解疾病并研究临床挑战，以改善医疗质量。而人体内的疾病诊断通常需要不同的医学成像技术，例如 CT 成像、磁共振成像（MRI）等。人体 2/3 的重量为水分，如此高的比例正是磁共振成像技术能被广泛应用于医学诊断的基础。人体内器官和组织中的水分并不相同，很多疾病的病理过程会导致水分形态的变化，即可由磁共振图像反应出来。

脑肿瘤分割被认为是医学领域中最困难的分割问题之一，神经胶质瘤是最常见的恶性脑肿瘤，具有不同程度的侵袭性^[2]。在磁共振成像(MRI)上对这些恶性肿瘤进行自动、准确的分割对于临床诊断至关重要。同时，准确肿瘤轮廓的描绘可以支持诊断、治疗计划和治疗反应监测从而显著提高治疗质量。此外，肿瘤及其相关亚区域的分割可以识别新的成像生物标志物，从而实现更精确和可靠的疾病分层和治疗反应预测^[3]。从 MRI 中可以定义四个不同的肿瘤亚区：“增强肿瘤”（ET），即 T1Gd 序列相对于 T1 序列的相对高信号强度区域；“非增强肿瘤”（NET）和“坏死肿瘤”（NCR），在 T1-Gd 序列中与 T1 相比，它们都是低信号强度；最后是“肿瘤周围水肿”（ED），在 FLAIR 序列中为高信号强度。这些几乎同质的亚区可以聚集在一起，组成三个“语义上”的肿瘤亚部分：ET 是第一个簇，添加 ET、NET 和 NCR 代表“肿瘤核心”（TC）区域，将 ED 添加到 TC 代表“整个肿瘤”（WT）。如下图 1 提供了每个序列和肿瘤子体积的例子。




图 1 四种成像序列的切面图和原始标签

心肌梗死（Myocardial infarction）是全世界导致死亡和残疾的主要原因^{[4][5]}。准确分析和建模心室和心肌的医学图像，是诊断和治疗心肌梗死患者的重要步骤^[6]。磁共

振成像用于临床工作流程中，以提供心脏的解剖和功能信息。不同类型的心脏磁共振（CMR）序列被获取以提供互补的信息，例如，T2 加权图像突出显示急性损伤和缺血区域，而 bSSFP 运动序列捕捉心脏动作并呈现清晰的边界。此外，LGE CMR 可以增强梗死心肌，与健康组织相比呈现出独特的亮度^[7]。它被广泛用于临床研究中研究心肌梗死的存在、位置和程度。因此，从 LGE CMR 图像中分割心室和心肌对于预测梗死风险、确定梗死组织的程度以及患者预后是重要的。下图是心脏 LGE MRI 成像的的切片数据和对应人工专家的标注。

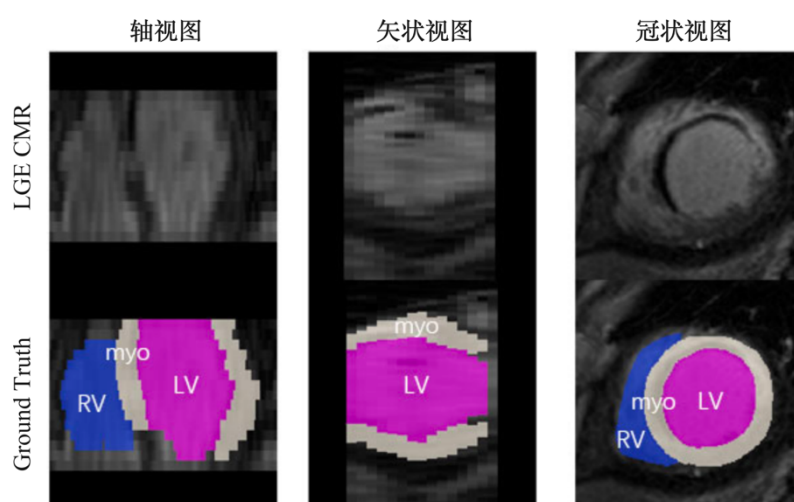


图 2 心脏 MRI 成像序列

上述背景充分说明了图像分割在诊断和治疗中发挥着积极作用。例如，准确的神经胶质瘤分割掩码可以帮助手术规划、术后观察，并提高生存率。

1.2 研究意义和价值

迄今为止，磁共振医学影像是筛查颅内病变的最主要方法。但是，颅内肿瘤磁共振影像往往存在“同影异病、同病异影”等情况，单靠影像通常不能识别出脑肿瘤属良性或恶性，更无法判别脑膜瘤、听神经瘤、髓母细胞瘤、胶质瘤等类型。

人工智能辅助诊断技术发展迅速，已经在越来越多的临床领域出现，对医生进行辅助诊断支持。虽然其诊断结果不能作为医疗诊断的最终结论，但在医生的诊断过程中可以起到辅助诊断的作用，为医生提供参考，大大提高了医生的诊断效率，并在很大程度上帮助医生减少漏误诊率。从狭义上讲，“深度学习”是指使用具有堆叠功能层的神经网络模型（通常层数大于 5）^[8]。神经网络能够学习高维的层次特征并近似任何连续函数^[9]。考虑到深度神经网络的成就和最新进展，一些调研报道了已开发的深度学习技术^{[10][11]}。自深度学习出现以来，FCNN（Fully Convolutional Neural

Networks), 在各种医学语义分割任务中取得了最先进的成果^{[12][13][14]}。基于体素的方法取得了令人鼓舞的结果, 并已成为 3D 医学图像分割的一种通用方法。最近成功的方法几乎都应用了基于 FCNN 的方法, 并采用了“U 形”架构^{[15][16][17]}, 这种高度对称的医学图像分割架构, 以 U-Net^[18]为代表, 在过去的许多年里主导了医学分割任务的设计范式。尽管它们取得了成功, 但一些问题开始显现出来。专家注释的高昂费用阻碍了模型利用足够的表征来预测高度准确的分割结果。另一方面, 三维医学图像中的体积不可避免地增加了图像的维度和分辨率, 导致处理单个体积图像时的复杂性增加。因此, 网络如果从头开始学习处理 3D 图像就必须考虑复杂性和模型大小问题。因此, 对于深度学习技术方法进行进一步的改进是非常有必要的工作。

近年来, 点云分析在分割方面取得了显著进展, 一些有潜力的工作已经将点云与其他领域结合起来。Ma 等人^[19]提出了 CoCs, 将图像视为一组未组织好的点, 余等人^[20]引入了 3DMedPT 来检查复杂的生物结构。其他有前途的工作, 如场景重建^{[21][22]}和人体动作识别^[23]被提出以进一步扩展点云在各种下游任务中的应用可能性。在分割任务中, 点云能够学习到的表示与基于 CNN 的方法所学习的表示一样先进。此外, 由于点云的非结构化性质, 它们可以比基于 CNN 的方法更有效地解决冗余问题, 从而为细粒度分割任务实现更好的结果。因此, 作为一种能够表示 3D 数据的方式, 如何利用点云数据表示的优势解决现有 3D 医学图像的问题是一个亟待解决的点和方向。

最近已经有了相关的工作将点云数据表示用在了医学影像的分析当中, Adapt Everywhere^[24]主要的重心是在无监督域自适应工作上, 使用点云数据作为了一种额外的形状信息对分割任务进行辅助, 作者假设在测试时使用点云引入额外的形状信息, 并结合熵适应策略, 能够进一步弥合源域和目标域之间的性能差距。为此, 他们将分割网络进行转换, 将点云形式的形状信息嵌入到专用的深度结构中, 使用辅助点云回归任务。Cai 等人^[25]提出使用点云在训练过程中融入形状信息, 使其分割模型能够意识到器官的形状和拓扑结构。他们的形状学习多任务网络利用分割模型的多尺度特征生成更详细的器官表面点云。

二、国内外研究现状及评述

2.1 磁共振图像分割方法研究现状

基于体素的分割网络。自从引入基于 CNN 的方法以来，基于体素的图像分割方法在医学图像分析中得到广泛应用，这些方法在各种 2D 和 3D 医学图像分割任务上取得了最先进的结果^{[26][27]}。在此之后，一些基于 U-Net 的改进方法被提出，包含一系列嵌套的、密集的跳跃连接^{[28][28][29][30][31]}。SegNet^[32]对 U 形网络的问题进行了重新思考，并搭建了一种轻量级的医学图像分割网络。

最近，由于基于 Transformer 的网络在 NLP 和计算机视觉中表现出强大的性能^{[33][34]}，越来越多的 Transformer 方法被提出，并在各种任务上展现了强大的性能^{[35][36][37][38]}。TransUNet^[39]是第一个将 Transformer 应用于改进医学图像分割结果的方法。TransUNet 将卷积网络视为特征提取器，用于生成输入切片的特征图。然后，在瓶颈层中应用 Patch 嵌入到特征图的 patches 中，而不是 ViT 中的原始图像^[40]。同时，类似于 TransUNet，Li 等人^[41]提出使用一个压缩注意力块来规范化 Transformer 的自注意力模块，并使用一个扩展块来学习眼底图像的多样化表示，这些都是在卷积网络的瓶颈层中实现的。TransFuse^[42]引入了一个 BiFusion 模块，以融合基于浅层卷积网络编码器和基于 Transformer 的分割网络的特征，以在 2D 图像上进行最终预测。与 TransUNet 相比，TransFuse 主要将自注意机制应用于输入嵌入层，以改进 2D 图像的分割模型。Yun 等人^[43]使用 Transformer 将光谱信息与由卷积特征编码的光谱信息相结合，以解决高光谱病理问题。Xu 等人^[44]广泛研究了 Transformer 和卷积神经网络之间的权衡，并提出了一种更高效的编码器 LeViT-UNet。Li 等人^[45]提出了一种新的上采样方法，并将其并入 UNet 的解码器中，以模拟长期依赖性和全局信息，以获得更好的重建结果。TransClaw U-Net^[46]在 UNet 中使用 Transformer 来处理更多的卷积特征金字塔。TransAttUNet^[47]探索了将 Transformer 自注意力与卷积全局空间注意力相结合的可行性。TransBTS 首次利用 3D 卷积网络提取空间体积特征，并对输入的 3D 图像进行下采样以产生分层表示。TransBTS 中编码器的输出被重塑成一个向量（即标记），并馈入 Transformer 进行全局特征建模，然后附加一个普通的卷积解码器来上采样特征图以实现重建目标。Swin Transformer^[48]提出了第一个基于 Transformer 的 U 形编码器-解码器网络。与基于 CNN 的方法相比，Transformer-based 模型学习到更强的特征表示，因为它们从整个输入序列中聚合信息。然而，它在训练过程中对训练数据量和 GPU 计算资源的需求更高。我们建议利用点云网络来嵌入从 MRI 体积医学图像中抽样的点数

据。

3D 医学图像主要包括 CT、MRI、超声图像等。MRI 序列是一系列的射频脉冲和梯度，生成了一组具有特定外观的图像，已经提出了许多用于语义性脑肿瘤分割的方法。BraTS2019 的最佳性能是 Jiang 等人，采用了两阶段级联的 U-Net 结构。BraTS2020 的最佳性能方法是 Isensee 等人，该方法在后处理、基于区域的训练和更激进的数据增强方面进行了一些 BraTS 特定的修改。与上述基于 CNN 的方法不同，我们探索了在 MRI 序列上进行点云分割的可能性。

点云分割网络。点云是将 3D 对象建模为一系列无序点的另一种有效方式。点云的一个关键特性是它们是非结构化的，这意味着点云没有像网格或体素网格那样的拓扑结构。这提供了灵活性，但同时也给点云处理带来了挑战。第一个直接处理原始点云的提出的方法是 PointNet^[49]。通过应用对称函数来利用点云结构的固有置换不变性，得到了全局特征表示。已经提出了几种基于点云的分割方法，包括^{[50][51][52][53]}。Lee 和 Kim^[54]提出了形状自适应滤波器，提取抗噪声或异常值的鲁棒特征。RandLA-Net 提出了一种随机局部聚合方法，利用局部特征聚合和全局特征挖掘策略。PointMLP^[55]引入了一个纯残差 MLP 网络，没有采用复杂的局部几何提取器，但仍能表现出很强的竞争力。然而，关于在医学影像环境中利用点云数据表示进行语义分割任务的现有研究非常少，并且，医学点云数据集也非常稀缺，3D Medical Point Transformer^[56]是使用了 Point Transformer 在 3D 颅内动脉瘤数据集(IntrA) 上的工作。据我们所知，Point-Unet^[57]架构是探索和验证利用点云数据结构进行医学影像分析的开创性工作。在这项工作的基础上，我们进一步探索了点云在体素医学图像分割中的巨大潜力。

三、研究思路和方法，研究工作方案和进度计划

3.1 研究思路与方法

受上述工作的启发，我们提出了一种基于点云表示的体素级分割方法。我们可以通过将三维医学图像转换为点云来利用点云分割方法执行分割任务。与体素这种数据类型相比，点云是一种无序、离散的数据结构。所学习的点云特征表示能够包含足够的信息，并具有更精细的分割结果。一些基于点的分割工作已经显示了点云的优势，如 SAT^[20]，RandLA-Net^[52]，并证明它有可能被用于其他分割任务。

将 3D 医学图像采样为点云数据是一个涉及多个步骤的技术过程。通常，这个过程可以分为以下几个主要步骤：获取 3D 医学图像：首先，获取 3D 医学图像，这些图像通常以 CT（计算机断层扫描）或 MRI（磁共振成像）的形式存在。这些图像通常是体素（三维像素）的形式存储的。我们的工作针对 MRI 图像。图像预处理：在提取点云之前，可能需要对图像进行预处理。这可能包括去噪声、对比度增强、边缘检测等步骤，以提高点云数据的质量。选择感兴趣的区域：在 3D 医学图像中，可能不是所有区域都是我们感兴趣的。因此，选择特定的解剖结构或感兴趣区域（ROI）是很重要的。点云采样：这是将 3D 医学图像转换为点云数据的关键步骤。可以通过多种方式完成，如：直接采样：从 3D 图像中直接选择点，将它们的坐标和可能的其他属性（如强度或颜色）转换成点云格式。表面重建：先从 3D 图像中重建出表面模型，然后从这个模型上采样点来生成点云。这里我们使用的是沿坐标进行随机采样。

我们首先要实现将医学体素数据采样为点云数据。这里的采样是一次性的，也就是说，只需要对体素进行采样并执行一次推理。我们的采样步骤如下。首先，我们对 3DMRI 成像进行裁剪，将图像裁剪到只包含整个器官部分。然后分别沿着每一个维度对每一个像素进行采样，将图像采样为点云。同时，我们可以选择对肿瘤部分采样点数的设置，以最佳数量的采样点的采样结果送入网络进行学习。

在这项工作中，我们利用了点云的高精度、无结构和高效性来分割脑肿瘤和心脏 MRI 医学图像，图 3 显示了所提出框架的整体流程。具体来说，我们通过将体医学图像采样为点云数据，将体素医学图像的分割任务转化为点云分割任务，并设计了一种针对点云数据的架构。该架构具有不对称的编码器-解码器结构，其中设计了双编码器来提取密集和稀疏特征。此外，两个学习到的特征在跳过连接处相减，并在每个阶段输入到相应的解码器中。然后对表示进行分层上采样，以生成用于分割点云的预测。随后，将分

割的点云转换回原始的体素 MRI 进行验证。

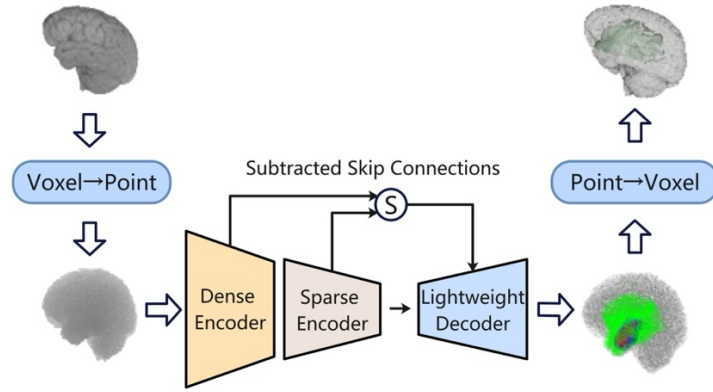


图 3 所提出的基于点云分割的架构

给定一组空间分辨率为 $H \times W$ 、切片数为 D 的脑部 MRI 扫描图像 $X \in R^{H \times W \times D}$ ，我们首先将 MRI 扫描图像采样为一组点云，即 $P = \{p_i | i = 1, \dots, N\} \in R^{N \times 4}$ 。其中 N 表示点的数量，每个点由笛卡尔空间中的 (x, y, z) 坐标和像素值组成。我们首先利用一个包含 4 级的双编码器分别捕获密集特征和稀疏特征，在每一级中，我们捕获并聚合点云的局部区域，并通过最远点采样（FPS）算法对 N 点进行重新采样，以逐步减少采样点。此外，在跳转连接处引入减法运算，以捕捉密集和稀疏特征之间的差异。之后，我们使用一个轻量级解码器，简单地将点上采样回原始点数，进行分割。我们拟提出的分割架构如下图 4 所示。

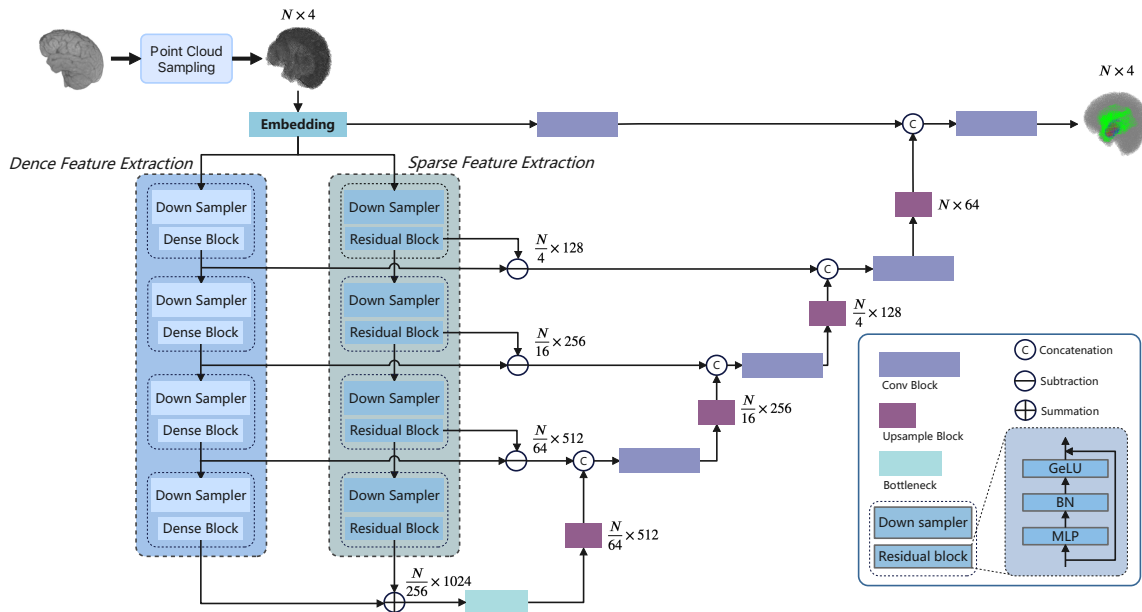


图 4 基于点云数据的双编码器分割架构

双编码器的输入点云 \mathcal{P} 首先通过嵌入层被映射为高维张量 $\mathcal{F}_e \in R^{N \times 64}$ ，然后将嵌入的特征输入双路径编码器进行特征提取。根据目前大模型的设计范式，一个重型的（heavy）编码器对于捕捉底层模式至关重要。于此同时，轻量级解码器用于重建原始数据。基于这种想法，我们设计了一种非对称模型，与典型的对称模型不同的地方在于我们设计了一种非对称架构，其中包含一个重型的双编码器来学习密集和稀疏的底层表征 \mathcal{F}_d 和 \mathcal{F}_s ，以及一个轻量级解码器对点云进行简单的上采样。

密集特征提取。对于每个密集特征提取阶段，输入点云首先通过采样块进行处理，该块使用最远点采样（FPS）算法将点的数量减少到 N_s ，然后将具有维度为 d 的采样点 $\{x_1, x_2, \dots, x_n\}$ 馈送到残差特征提取块中，该块包含 3 层多层感知机层（MLP），然后使用一个对称函数（PointNet++ 中的最大池化）将学习到特征集进程聚合，密集特征提取操作可以表示为：

$$\mathcal{F}_d(x_1, x_2, \dots, x_n) = \mathcal{A}(h(x_i) \mid i = 1, \dots, n) \quad (1)$$

其中 \mathcal{A} 是对称函数（PointNet++ 中的 max-pooling）， h 是多层感知机（MLP）网络，请注意，对称函数使提取器对输入点云具有了排列不变性(permutation invariance)。通过这样做，我们的密集提取器能够逐步捕获具有代表性的信息。

稀疏特征提取。尽管我们获得了密集的特征，但它们不足以高精度地完成分割任务，为了捕获稀疏表示，我们遵循 PointMLP 的框架，构建了一个简单的残差 MLP 网络，该网络将局部特征分层聚合，因为 MLP 具有排列不变性，这完全符合点云的特征。在每个阶段中，输入特征在聚合操作之前和之后都经过一个提取模块，每个提取模块都包含残差的 MLP 层。通过堆叠多个级，编码器逐渐扩大感受野。

减法跳过连接。尽管编码器可以生成每个阶段的密集和稀疏特征，但将两种不同的特征同时传递给解码器不可避免地会导致冗余，甚至干扰解码过程。为了合理地利用编码器在每个层学到的表示，我们提出了减法跳过连接，将编码器学到的表示传递到解码器。具体来说，对于每个阶段生成的输出表示，我们将密集表示和稀疏表示进行相减的操作。通过这种方式，获得的表示在不过度冗余的情况下，弥补了密集信息和稀疏信息之间的差异性信息。

轻量级的解码器。在我们的编码器末端，我们使用特征传播模块将学到的特征点上

采样到上层类别的数量。然后，我们将上采样的特征点与先前跳过连接得到的差异性特征进行拼接，并将它们输入到连续的 1D 卷积层中，以映射特征。在每个解码器阶段重复此操作，直到达到原始输入点的数量，其中最终的输出被输入到 1D 卷积层中以生成逐点语义预测。

3.2 研究工作方案和进度计划

(1) 2022 年 10 月 —— 2023 年 4 月：广泛阅读文献，综述。大致确定研究方向和研究的主要问题。进行文献综述，系统性地总结、分析已有研究，明确目前该领域存在的主要研究问题和未解决的难点。

(2) 2023 年 5 月 —— 2023 年 11 月：确定研究方向并进行可行性分析，通过实验对研究思路进行初步验证，验证点云数据表示用在医学图像上的可行性。开展初步实验或调研，验证研究思路的可行性，收集初步数据，并分析初步结果。

(3) 2023 年 12 月 —— 2024 年 7 月：设计总体的方法框架，完成对数据的预处理，通过实验对方法进行验证，完成对比实验和消融实验。

(4) 2024 年 8 月 —— 2025 年 3 月：整理资料并撰写毕业论文，论文初稿可能需要多次修改和完善，确保逻辑清晰、结构完整，符合学术要求。

(5) 2025 年 4 月：修改、完善论文并准备毕业论文答辩。

四、前期研究基础及主要参考文献

4.1 前期研究基础

工作准备阶段

开始阅读和收集相关文献，了解所研究领域的先前研究成果。整理和总结最新最紧的学术成果。主要聚焦于当前研究领域的核心问题和已有研究中存在的空白或不足。通过对文献的全面审视，已经明确了研究中的理论框架和方法论基础，以便于在后续研究中构建合适的研究方法和设计。前期研究基础为后续研究工作提供了关键的理论和实证支持，为解决该领域内的问题和填补知识空白奠定了重要基础。

在实践方面：首先，掌握基础的机器学习理论，包括神经网络结构、优化算法等基本概念；然后，学习相关深度学习框架（PyTorch），掌握它们的基本操作和 API 调用，理解其工作原理；接着，通过阅读和实践经典的深度学习模型、算法和相关论文，了解各种模型的原理及应用场景；最后，积累实践经验，通过编写简单的示例代码、完成小规模项目或参与开源项目，提升编程能力和深度学习实践技能。

4.2 当前工作进展

(1) 引入了一种基于点云数据表示的分割方法，将体素医学图像转换为点云数据用于医学图像分割。

(2) 提出了一种双编码器，它集成了密集和稀疏表示。此外，在解码阶段通过传递密集和稀疏表示的差值来提供互补特征。

(3) 已经在两个临床分割任务上进行了全面的实验，包括脑肿瘤和心脏结构。

(4) 开始撰写论文《Dense-sparse Representation Matters: A Point-based Method for Volumetric Medical Image Segmentation》。

4.3 拟使用的数据集

BraTS^[58]。BraTS 提供了最大的完全注释的公开可用脑肿瘤数据集，用于模型开发。BraTS 一直专注于评估最先进的脑肿瘤分割方法，在多模态磁共振成像(MRI)扫描中进行。BraTS19/BraTS20 中包含 335/369 例患者的训练样本和 125/125 例验证样本。每个样本由四种大脑 MRI 扫描模式组成，即原生 T1 加权(T1)、后对比 T1 加权(T1ce)、T2 加权(T2)和液体衰减反转恢复(FLAIR)。每个模态的体积为 $240 \times 240 \times 155$ ，已对齐到相同的空间中，体素间距为 $1.0 \times 1.0 \times 1.0\text{mm}^3$ 。对于 BraTS 中的点云采样，我们在 BraTS 中采样了 365,000 个点。

MS-CMRSeg^[59]。对于多序列心脏 MRI 分割任务，来自 45 名患有心肌病的患者的 CMR 数据已经获得机构伦理批准并已匿名化。每个患者都使用三种 CMR 序列进行了扫描，即 LGE、T2 和 bSSFP。这三种 CMR 序列都是屏气、多切片的，在心室短轴视图中采集。groundtruth 轮廓是由两名专家标注的，包括右心室(RV)腔、LV 腔和心肌区域。所有患者的 bSSFP 和 T2 CMR 用于训练，患者 1-5 的 LGE CMR 用于验证，然后患者 6-45 的 LGE CMR 用于测试。此挑战的目标是通过将在 45 张带注释的 bSSFP 图像上学到的知识进行迁移，从 40 张 LGE CMR 图像中分割出右心室血腔（RVC），左心室血腔（LVC）和左心室心肌（MYO）。我们将对每一个数据样本采样 10000 个点。

4.4 参考文献

- [1] Monteiro M, Newcombe V F J, Mathieu F, et al. Multiclass semantic segmentation and quantification of traumatic brain injury lesions on head CT using deep learning: an algorithm development and multicentre validation study[J]. The Lancet Digital Health, 2020, 2(6): e314-e322.
- [2] Wang W, Chen C, Ding M, et al. Transbts: Multimodal brain tumor segmentation using transformer[C]//Medical Image Computing and Computer Assisted Intervention–MICCAI 2021: 24th International Conference, Strasbourg, France, September 27–October 1, 2021, Proceedings, Part I 24. Springer International Publishing, 2021: 109-119.
- [3] Isensee F, Jäger P F, Full P M, et al. nnU-Net for brain tumor segmentation[C]//Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries: 6th International Workshop, BrainLes 2020, Held in Conjunction with MICCAI 2020, Lima, Peru, October 4, 2020, Revised Selected Papers, Part II 6. Springer International Publishing, 2021: 118-132.
- [4] Kim H W, Farzaneh-Far A, Kim R J. Cardiovascular magnetic resonance in patients with myocardial infarction: current and emerging applications[J]. Journal of the American College of Cardiology, 2009, 55(1): 1-16.
- [5] Timmis A, Townsend N, Gale C, et al. European Society of Cardiology: cardiovascular disease statistics 2017[J]. European heart journal, 2018, 39(7): 508-579.
- [6] Zhuang X. Multivariate mixture model for myocardial segmentation combining multi-source images[J]. IEEE transactions on pattern analysis and machine intelligence, 2018, 41(12): 2933-2946.
- [7] Hammer-Hansen S, Bandettini W P, Hsu L Y, et al. Mechanisms for overestimating acute myocardial infarct size with gadolinium-enhanced cardiovascular magnetic resonance imaging in humans: a quantitative and kinetic study[J]. European Heart Journal-Cardiovascular Imaging, 2016, 17(1): 76-84.
- [8] Goodfellow I, Bengio Y, Courville A. Deep learning[M]. MIT press, 2016.

- [9] Lin H, Jegelka S. Resnet with one-neuron hidden layers is a universal approximator[J]. Advances in neural information processing systems, 2018, 31.
- [10] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.
- [11] Gu J, Wang Z, Kuen J, et al. Recent advances in convolutional neural networks[J]. Pattern recognition, 2018, 77: 354-377.
- [12] Bakas S, Reyes M, Jakab A, et al. Identifying the best machine learning algorithms for brain tumor segmentation, progression assessment, and overall survival prediction in the BRATS challenge[J]. arXiv preprint arXiv:1811.02629, 2018.
- [13] Simpson A L, Antonelli M, Bakas S, et al. A large annotated medical image dataset for the development and evaluation of segmentation algorithms[J]. arXiv preprint arXiv:1902.09063, 2019.
- [14] Heller N, Sathianathen N, Kalapara A, et al. The kits19 challenge data: 300 kidney tumor cases with clinical context, ct semantic segmentations, and surgical outcomes[J]. arXiv preprint arXiv:1904.00445, 2019.
- [15] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3431-3440.
- [16] Isensee F, Jäger P F, Full P M, et al. nnU-Net for brain tumor segmentation[C]//Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries: 6th International Workshop, BrainLes 2020, Held in Conjunction with MICCAI 2020, Lima, Peru, October 4, 2020, Revised Selected Papers, Part II 6. Springer International Publishing, 2021: 118-132.
- [17] Isensee F, Jaeger P F, Kohl S A A, et al. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation[J]. Nature methods, 2021, 18(2): 203-211.
- [18] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18. Springer International Publishing, 2015: 234-241.
- [19] Ma X, Zhou Y, Wang H, et al. Image as Set of Points[J]. arXiv preprint arXiv:2303.01494, 2023.
- [20] Zhou J, Xiong Y, Chiu C, et al. SAT: Size-Aware Transformer for 3D Point Cloud Semantic Segmentation[J]. arXiv preprint arXiv:2301.06869, 2023.
- [21] Chen Z, Ledoux H, Khademi S, et al. Reconstructing compact building models from point clouds using deep implicit fields[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2022, 194: 58-73.
- [22] Nie Y, Hou J, Han X, et al. Rfd-net: Point scene understanding by semantic instance reconstruction[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and

Pattern Recognition. 2021: 4608-4618.

- [23] Li X, Huang Q, Wang Z, et al. VirtualActionNet: A strong two-stream point cloud sequence network for human action recognition[J]. Journal of Visual Communication and Image Representation, 2022, 89: 103641.
- [24] Vesal S, Gu M, Kosti R, et al. Adapt everywhere: unsupervised adaptation of point-clouds and entropy minimization for multi-modal cardiac image segmentation[J]. IEEE Transactions on Medical Imaging, 2021, 40(7): 1838-1851.
- [25] Cai J, Xia Y, Yang D, et al. End-to-end adversarial shape learning for abdomen organ deep segmentation[C]//Machine Learning in Medical Imaging: 10th International Workshop, MLMI 2019, Held in Conjunction with MICCAI 2019, Shenzhen, China, October 13, 2019, Proceedings 10. Springer International Publishing, 2019: 124-132.
- [26] Jiang Z, Ding C, Liu M, et al. Two-stage cascaded u-net: 1st place solution to brats challenge 2019 segmentation task[C]//Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries: 5th International Workshop, BrainLes 2019, Held in Conjunction with MICCAI 2019, Shenzhen, China, October 17, 2019, Revised Selected Papers, Part I 5. Springer International Publishing, 2020: 231-241.
- [27] Çiçek Ö, Abdulkadir A, Lienkamp S S, et al. 3D U-Net: learning dense volumetric segmentation from sparse annotation[C]//Medical Image Computing and Computer-Assisted Intervention–MICCAI 2016: 19th International Conference, Athens, Greece, October 17-21, 2016, Proceedings, Part II 19. Springer International Publishing, 2016: 424-432.
- [28] Zhou Z, Rahman Siddiquee M M, Tajbakhsh N, et al. Unet++: A nested u-net architecture for medical image segmentation[C]//Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support: 4th International Workshop, DLMIA 2018, and 8th International Workshop, ML-CDS 2018, Held in Conjunction with MICCAI 2018, Granada, Spain, September 20, 2018, Proceedings 4. Springer International Publishing, 2018: 3-11.
- [29] Dolz J, Gopinath K, Yuan J, et al. HyperDense-Net: a hyper-densely connected CNN for multi-modal image segmentation[J]. IEEE transactions on medical imaging, 2018, 38(5): 1116-1126.
- [30] Bui T D, Shin J, Moon T. 3D densely convolutional networks for volumetric segmentation[J]. arXiv preprint arXiv:1709.03199, 2017.
- [31] Yu L, Cheng J Z, Dou Q, et al. Automatic 3D cardiovascular MR segmentation with densely-connected volumetric convnets[C]//Medical Image Computing and Computer-Assisted Intervention– MICCAI 2017: 20th International Conference, Quebec City, QC, Canada, September 11-13, 2017, Proceedings, Part II 20. Springer International Publishing, 2017: 287-295.
- [32] Cheng J, Gao C, Wang F, et al. SegNetr: Rethinking the local-global interactions and skip

- connections in U-shaped networks[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer Nature Switzerland, 2023: 64-74.
- [33] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [34] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [35] Wang W, Chen C, Ding M, et al. Transbts: Multimodal brain tumor segmentation using transformer[C]//Medical Image Computing and Computer Assisted Intervention–MICCAI 2021: 24th International Conference, Strasbourg, France, September 27–October 1, 2021, Proceedings, Part I 24. Springer International Publishing, 2021: 109-119.
- [36] Hatamizadeh A, Tang Y, Nath V, et al. Unetr: Transformers for 3d medical image segmentation[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2022: 574-584.
- [37] Hatamizadeh A, Xu Z, Yang D, et al. Unetformer: A unified vision transformer model and pre-training framework for 3d medical image segmentation[J]. arXiv preprint arXiv:2204.00631, 2022.
- [38] He S, Bao R, Grant P E, et al. U-Netmer: U-Net meets Transformer for medical image segmentation[J]. arXiv preprint arXiv:2304.01401, 2023.
- [39] Chen J, Lu Y, Yu Q, et al. Transunet: Transformers make strong encoders for medical image segmentation[J]. arXiv preprint arXiv:2102.04306, 2021.
- [40] Zhou D, Kang B, Jin X, et al. Deepvit: Towards deeper vision transformer[J]. arXiv preprint arXiv:2103.11886, 2021.
- [41] Li S, Sui X, Luo X, et al. Medical image segmentation using squeeze-and-expansion transformers[J]. arXiv preprint arXiv:2105.09511, 2021.
- [42] Zhang Y, Liu H, Hu Q. Transfuse: Fusing transformers and cnns for medical image segmentation[C]//Medical Image Computing and Computer Assisted Intervention–MICCAI 2021: 24th International Conference, Strasbourg, France, September 27–October 1, 2021, Proceedings, Part I 24. Springer International Publishing, 2021: 14-24.
- [43] Yun B, Wang Y, Chen J, et al. Spectr: Spectral transformer for hyperspectral pathology image segmentation[J]. arXiv preprint arXiv:2103.03604, 2021.
- [44] Xu G, Wu X, Zhang X, et al. Levit-unet: Make faster encoders with transformer for medical image segmentation[J]. arXiv preprint arXiv:2107.08623, 2021.
- [45] Li Y, Cai W, Gao Y, et al. More than encoder: Introducing transformer decoder to upsample[C]//2022 IEEE International Conference on Bioinformatics and Biomedicine (BIBM). IEEE, 2022: 1597-1602.
- [46] Chang Y, Menghan H, Guangtao Z, et al. Transclaw u-net: Claw u-net with transformers

- for medical image segmentation[J]. arXiv preprint arXiv:2107.05188, 2021.
- [47] Chen B, Liu Y, Zhang Z, et al. Transattunet: Multi-level attention-guided u-net with transformer for medical image segmentation[J]. IEEE Transactions on Emerging Topics in Computational Intelligence, 2023.
- [48] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [49] Qi C R, Su H, Mo K, et al. Pointnet: Deep learning on point sets for 3d classification and segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 652-660.
- [50] Qi C R, Yi L, Su H, et al. Pointnet++: Deep hierarchical feature learning on point sets in a metric space[J]. Advances in neural information processing systems, 2017, 30.
- [51] Li Y, Bu R, Sun M, et al. Pointcnn: Convolution on x-transformed points[J]. Advances in neural information processing systems, 2018, 31.
- [52] Hu Q, Yang B, Xie L, et al. Randla-net: Efficient semantic segmentation of large-scale point clouds[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11108-11117.
- [53] Yan X, Zheng C, Li Z, et al. Pointasnl: Robust point clouds processing using nonlocal neural networks with adaptive sampling[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 5589-5598.
- [54] Lee S H, Kim C S. SAF-Nets: Shape-Adaptive Filter Networks for 3D point cloud processing[J]. Journal of Visual Communication and Image Representation, 2021, 79: 103246.
- [55] Ma X, Qin C, You H, et al. Rethinking network design and local geometry in point cloud: A simple residual MLP framework[J]. arXiv preprint arXiv:2202.07123, 2022.
- [56] Yu J, Zhang C, Wang H, et al. 3d medical point transformer: Introducing convolution to attention networks for medical point cloud analysis[J]. arXiv preprint arXiv:2112.04863, 2021.
- [57] Ho N V, Nguyen T, Diep G H, et al. Point-unet: A context-aware point-based neural network for volumetric segmentation[C]//Medical Image Computing and Computer Assisted Intervention–MICCAI 2021: 24th International Conference, Strasbourg, France, September 27–October 1, 2021, Proceedings, Part I 24. Springer International Publishing, 2021: 644-655.
- [58] U.Baid, et al., "The RSNA-ASNR-MICCAI BraTS 2021 Benchmark on Brain Tumor Segmentation and Radiogenomic Classification", arXiv:2107.02314, 2021
- [59] Xiahai Zhuang: Multivariate mixture model for myocardial segmentation combining multi-source images. IEEE Transactions on Pattern Analysis and Machine Intelligence (T PAMI), vol. 41, no. 12, 2933-2946, 2019. link code

五、拟解决的主要问题、研究的主要内容

5.1 解决的主要问题

(1) 三维医学图像中的体积不可避免地增加了图像的维度和分辨率，导致处理单个体素图像的复杂性增加。因此，需要找到一种合适的方案解决 3D 数据复杂度的问题。

(2) 之前的方法很少有将点云数据和医学图像来结合分析的。我们将探索如何将磁共振图像具有的特点与点云分割的网络相结合设计一个针对医学点云的分割网络。

5.2 研究的主要内容

(1) 提出了一种基于点云表示的体素分割方法。我们可以利用一种点云分割方法，通过将三维医学图像转换为点云来执行分割任务。与体素相比，点云是一种无序、离散的数据结构。所学习的 PC 表示能够包含足够的信息，并且具有更精细的分割结果。

(2) 双路编码器进行特征提取。双编码器的输入点云 \mathcal{P} 首先通过嵌入层被映射为高维张量 $\mathcal{F}_e \in R^{N \times 64}$ ，然后将嵌入的特征输入双路径编码器进行特征提取。根据目前大模型的设计范式，一个重型的（heavy）编码器对于捕捉底层模式至关重要。于此同时，轻量级解码器用于重建原始数据。基于这种想法，我们设计了一种非对称模型，与典型的对称模型不同的地方在于我们设计了一种非对称架构，其中包含一个重型的双编码器来学习密集和稀疏的底层表征 \mathcal{F}_d 和 \mathcal{F}_s ，以及一个轻量级解码器对点云进行简单的上采样。

六、重点难点、主要观点及创新之处

6.1 重点难点

重点：

(1) 3D 的体素数据相较于 2D 的数据复杂度更高，如果要从头开始训练一个 3D 的网络会大大增加计算的时间成本。

(2) 将体素医学数据采样为点云数据，应该如何采样能够保持原来数据包含的信息不被丢失。

(3) 针对医学点云的分割网络应该如何去构建，如何提取到关键的信息。

难点：

(1) 设计一个适合的采样方法，能够将 3D 数据采样为点云数据同时也保存了相关的信息。

(2) 如何根据点云数据表示的特征设计一个针对于医学点云的分割网络，使得网络能够更好的捕获点云数据的表征信息。

(3) 如何构建一个泛化能力强大的网络，能够处理各种类型的医学点云数据。

6.2 主要观点及创新之处

(1) 我们引入了一种新颖的基于点云的三维方法，将 3D 体素医学图像转换为点云用于医学图像分割。

(2) 我们提出了一种双编码器，它集成了密集和稀疏表示。此外，在解码阶段通过减去密集和稀疏表示来提供互补特征。

(3) 我们在两个临床分割任务上进行了全面的实验，包括脑肿瘤和心脏结构。实验结果表明，我们的方法具有竞争力，这表明进一步开发基于点云的医学图像分割算法是可行的。

七、论文写作提纲

摘要

第一章 绪论

第二章 相关理论

第三章 基于点云数据表示的磁共振图像分割方法

第四章 基于自监督点云的磁共振图像预训练分割方法

第五章 总结与展望

参考文献

致谢

攻读硕士学位期间发表的学术论文

八、导师意见

(选题的现实意义及应用价值、选题的创新性、学生的准备情况、完成选题的可行性、论文的结构设计等):

该生选题是基于点云数据表示的磁共振图像分割方法研究，并引入了一种新的不对称分割架构。这种方法通过将体积医学图像采样成点云，然后使用特定的网络进行处理，从而实现体积医学图像的分割。研究内容包括：

拟提出了一个双路径编码器，该编码器能够充分捕捉从体积中采样的输入点云的密集和稀疏表示。这两种表示在跳跃连接处相减，作为解码阶段的互补特征。研究回顾了体素分割网络和点云分割网络的相关研究，指出了现有方法在处理体积医学图像时的局限性，并探讨了点云在医学图像分割中的应用前景。

该生工作安排合理，态度认真，其选题立意明确，具备可能性，研究内容充实，方法切实有效，论文结构设计合理。

同意开题。

导师签名: 年 月 日

九、开题记录

(开题中提出的主要问题及回答的简要情况):

1. 论文题目不需要加“应用”，下来再和老师进行讨论。

回答：答辩结束后会与导师进行讨论,重新修改论文题目。

2. 进度安排加入每个阶段的细节工作，完成了哪一部分的工作，做了哪些实验等等。

回答：将在工行进展的每一个部分加入具体的工作和安排。

3. 论文三四章的工作最好是相关的，再讨论一下三四章的题目。

回答：下来会继续重新思考下论文三四章的工作。

4. 工作中对于 3D医学图像数据如何采样为点云数据没有具体的讲解，这一部分其实内容很重要，需要在最开始讲清楚医学图像数据是什么，点云数据是什么，如何将医学图像采样为点云数据？

回答：将在报告中增加医学图像数据和点云数据的具体介绍。

5. 报告中还存在部分细节的排版问题。

回答：会把报告中的细节问题进行逐一修改。

6. “导师意见”处出现了过于详细的研究内容描述，且出现了“具有足够的工作量”的叙述。

回答：这部分的内容都是参考了上届师兄的写法自己写的，也经过了导师的同意;会在回去后重新与导师商议，删除多余内容。

开题记录人签字：

年 月 日

十、研究生修改情况

1. 论文题目修改为“基于点云数据表示的磁共振图像分割方法研究及应用”。
2. 工作进展加入了每一个阶段的工作细节。
3. 重新思考了第四章的内容并且将合理设置三四章的题目，使得题目尽可能相关联。
4. 在报告中增加了医学图像数据和点云数据的具体介绍，加入了如何将医学图像采样为点云数据的内容。
5. 对报告中的排版细节问题进行了修改。
6. 对“导师意见”部分进行了修改，重新描述了导师意见。

导师审核意见：

导师签字：

年 月 日

附件 1:

西北师范大学研究生学位论文开题报告评审表

姓 名	刘柄汐	学 号	2022222292	所在学院	计算机科学与工程学院
学生类型	<input type="checkbox"/> 博士 <input checked="" type="checkbox"/> 硕士； <input type="checkbox"/> 学术学位 <input checked="" type="checkbox"/> 专业学位； <input checked="" type="checkbox"/> 全日制 <input type="checkbox"/> 非全日制				
论文题目	基于点云数据表示的磁共振图像分割方法研究及应用			指导教师	蒋芸
评审小组意见	<p>（从论文选题价值、文献综述质量、研究内容和方法的合理性以及研究计划的可行性等方面进行综合评价）</p> <p>该论文做了基于点云数据表示的磁共振图像分割方法研究，研究了基于点云表示的磁共振图像分割方法，提出以一种针对医学点云数据的分割模型。进一步研究了点云自监督方法在医学磁共振图像上的分割能力。</p> <p>选题具有一定的理论意义与研究价值，该生在该研究领域做了大量的准备工作，广泛阅读文献，充分了解该研究领域的研究现状，对研究内容理解透彻，研究方法具有可行性。该生研究进度安排合理，态度认真，综上同意开题。</p> <p>评审结果（通过、不通过两类）： _____</p> <p>评审小组组长签字： _____ 年 月 日</p>				
培养学院意见	<p>培养学院负责人签字： _____ （单位公章）</p> <p>_____ 年 月 日</p>				